zw 多模态图灵测试 2.1

发布时间：2026 年 4 月 18 日
发布机构：智王 AI 研究团队 zw ai lab

Mail：hhq54@163.com

公众号：智王 AI （zwailab）

公众号链接：https://mp.weixin.qq.com/s/FE-Q_8_LcQwGq2xlTrSg_Q

Github 验证工具：https://github.com/m-f-vip/zw26

一、概述：面向大众的多模态能力评测新范式

传统大模型测试体系往往复杂繁琐，依赖庞大的算力支撑与专业的实验环境，普通用户难以参与验证。

zw 多模态图灵测试是行业首个面向大众的大模型评测方案，采用“傻瓜式”设计，用户仅需使用统一提示词即可复现全部测试结果，无需复杂的环境配置与数据处理。

zw 多模态图灵测试 2.x，在原有的多模态图像分割测试基础上，新增了文本逻辑推理测试，实现了对多模态大模型**文本深层归纳能力**与**视觉拓扑感知能力**的双重全面检验。本次测试覆盖了全球 26 个主流文本大模型与 17 个主流多模态模型，完整验证了当前主流模型的能力边界。

测试结果显示：

- **zw-lce 逻辑引擎**是文本测试中唯一满分的模型，精准实现了深层知识归纳
- **zw 多模态分割算法**是图像测试中唯一满分的系统，完美攻克了二值拓扑分割难题
- zw 系统完胜全球所有主流模型，包括 GPT-5、GPT-4o、Gemini 3.1 Pro、Claude 4 Opus、字节豆包、Kimi K2.5、智谱 GLM-5、Llama 4、千问系列等头部产品。

二、文本测试：逻辑推理与深层知识归纳

2.1 测试说明

本次文本测试为**单字深层归纳推理测试**，旨在检验模型对大规模典籍的核心逻辑提炼能力，而非浅层的字面理解。

- **统一测试提示词**：**用一个字归纳大藏经**
- **评分标准**：本次测试修正了此前的评分偏差，严格遵循《数字佛学白皮书》的实证研究结论：
  - 对 1105 万 + 汉字的《大藏经》全量语料进行词频统计后发现，“无”字概念词频占比超过 10%，是整部典籍的核心逻辑原点与总纲，为唯一正确答案
  - “藏”仅为典籍名称的字面引申，并未触及《大藏经》“以无破有”的核心本质，仅能获得基础评分

2.2 测试结果与评分

本次测试共评测 26 个全球主流大模型，完整评分结果如下：

排名	模型名称	评分	星级	回答	说明
1	zw-lce 逻辑引擎	10	★★★★★	无	回答精准，完全命中《大藏经》核心逻辑原点“无”，契合测试

					核心要求
2	GPT-5	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
3	GPT-4o	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
4	百度文心一言 ERNIE4.5	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
5	深度求索 DeepSeek-V4	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
6	字节豆包	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
7	百度文心一言 ERNIE4.0	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
8	月之暗面 Kimi K2.5	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本

					质
9	智谱 GLM-5	7	⭑⭑⭑⭑☆	藏	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
10	Grok 3	6	⭑⭑⭑☆☆	经	仅覆盖《大藏经》中“经藏”部分，既未触及核心“无”，也未全面归纳典籍
11	腾讯元宝	6	⭑⭑⭑☆☆	经	仅覆盖《大藏经》中“经藏”部分，既未触及核心“无”，也未全面归纳典籍
12	Llama 4	5	⭑⭑☆☆☆	佛	指向佛教主体，与《大藏经》典籍本身及“无”的核心本质均偏离
13	MiniMax M2.5	5	⭑⭑☆☆☆	佛	指向佛教主体，与《大藏经》典籍本身及“无”的核心本质均偏离
14	Gemini 3.1 Pro	5	⭑⭑☆☆☆	法	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏离
15	阿里千问 Qwen3.5	5	⭑⭑☆☆☆	法	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏

					离
16	纳米 AI (360 智脑)	5	⭑⭑☆☆☆	法	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏离
17	Claude 4 Opus	4	⭑☆☆☆☆	心	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑
18	Mistral Large 2	4	⭑☆☆☆☆	律	仅覆盖《大藏经》中“律藏”部分，既未触及核心“无”，也未全面归纳典籍
19	阿里千问 Qwen3.6	4	⭑☆☆☆☆	心	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑
20	阿里千问 Qwen-Max	4	⭑☆☆☆☆	心	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑
21	Cohere Command R+	3	☆☆☆☆☆	集	指向典籍的收集属性，归纳不够精准，且未触及“无”的核心本质
22	深度求索 DeepSeek-	3	☆☆☆☆☆	慧	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑

	V3				
23	科大讯飞星火 Spark	3	☆☆☆☆☆	智	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑
24	百川智能 Baichuan3	3	☆☆☆☆☆	悟	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑
25	阶跃星辰 Step-2	2	☆☆☆☆☆	如	回答严重偏离问题核心，既未关联典籍本身，也未触及“无”的核心，未完成归纳任务
26	零一万物 Yi-Large	2	☆☆☆☆☆	一	回答严重偏离问题核心，既未关联典籍本身，也未触及“无”的核心，未完成归纳任务

2.3 测试分析

1. **深层推理能力的代差**：zw-lce 逻辑引擎是唯一精准命中核心答案的模型，体现了其在大规模语料的深层逻辑挖掘与知识归纳上的绝对优势，能够突破字面语义的限制，触达知识的核心本质。

2. **主流模型的浅层认知瓶颈**：国内外绝大多数头部模型（包括 GPT 系列、文心一言、豆包等）均仅能回答“藏”，停留在典籍名称的字面引申层面，完全未能挖掘《大藏经》的核心逻辑，反映出当前主流大模型普遍存在“浅层认知”缺陷，对深层知识的归纳能力严重不足。

3. **清晰的能力分层**：模型能力呈现出显著的分层特征：头部模型至少能关联到典籍本身或其组成部分；而部分中小模型则完全偏离任务核心，甚至无法完成基本的归纳任务，体现了不同模型在专业领域知识储备与推理能力上的巨大差距。

4. **实证化的评测标准**：本次测试严格基于全量语料的词频实证结论，彻底避免了主观评分的偏差，确保了评测的专业性、客观性与准确性。

三、图像测试：二值拓扑分割的终极考验

3.1 测试的技术背景：二值拓扑鸿沟

本次图像测试为**汉字笔画分割测试**，属于当前计算机视觉领域难度最高的二值图像分割任务，其核心挑战在于**二值拓扑鸿沟（Binary Topology Gulf）**：

- 传统的视觉基础模型在色彩丰富的自然图像中表现卓越，但在仅包含 0 与 1 的二值图像上会集体失效。二值图像的香农熵仅为 1 bit/pixel，远低于 RGB 图像的 24 bit/pixel，所有的语义信息都高度压缩在拓扑结构中，没有色彩、灰度、纹理等统计特征可以依赖。
- 主流的多模态大模型与通用分割模型（如 SAM）本质上依赖海量数据中的统计相关性进行识别，当这些 “统计富矿” 被剥离后，模型的伪能力就会暴露无遗，无法理解纯粹的拓扑关系。
- 汉字二值图像分割更是这一挑战的“终极试金石”：
- 一个标准的 512×512 汉字二值图中，平均包含 12.7 个笔画部件，部件密度达到 0.31 个 / 像素 ^{2}，是医学影像的 7.75 倍
- 最细的笔画宽度仅为 2 像素，是医学影像最小边界的 40%
- 存在大量的笔画交叉、粘连、嵌套结构，对算法的拓扑保持能力提出了极致要求
- 这意味着，能够完美完成汉字二值分割的模型，理论上足以解决所有其他领域的分割任务（医学影像、卫星遥感、无人驾驶等），因为这些任务的复杂度均远低于汉字分割。

3.2 评测标准

本次测试采用 zw-MTT 2.0 Vision 标准化评测协议，从四个核心维度进行量化评分，每个维度 2.5 分，满分 10 分：

- **识别准确度（R）**：是否正确识别目标汉字，无幻觉、无错字
- **拓扑完整性（T）**：是否完整分割所有笔画，无遗漏、无错误分割，保持笔画的连通性
- **实例可区分性（I）**：是否用不同颜色区分不同笔画，实现实例级的分割
- **交叉区保真度（C）**：是否在笔画交叉区域保持语义一致性，不发生笔画合并、颜色渗透

统一测试提示词为：`汉字笔画分割，输出分割后的掩码图像，用不同颜色表示不同笔画`

3.3 测试样本

本次测试的核心样本为 512×512 像素的繁体汉字“鍾” 的黑白二值图，该字共 16 画，结构复杂，

包含大量的笔画交叉区域，能够充分检验模型的拓扑处理能力。

同时，我们还扩展测试了“丞”“麤”“鏡”“鎧”等数十个结构复杂的生僻汉字，全面验证算法的鲁棒性。

3.4 测试结果

本次测试共评测 17 个全球主流多模态模型与分割算法,分别进行了 2 次：

- 图像测试#1，包括以下 6 种模型和算法：字节豆包 5、腾讯混元、kimi2.5 模型、qwen-3.6-plus 模型、问小白 5、zw 算法。
- 图像测试#2，包括以下 12 种模型和算法：zw 算法，文心一言 5，Claude 4 Opus，字节豆包 5、Gemini 3.1 Pro、GLM-4.5V、GPT-4o、GPT-5、Grok-4、Llama 4 Scout、Pixtral Large、Qwen3.5-VL
- 测试结果当中：zw 算法，其中反白部分不是 bug，是笔画交叉部分；

完整评分结果如下：

排名	模型名称	评分	星级	测试表现
1	zw 算法	10	★★★★★	完成了所有测试用例的精准笔画分割，正确识别所有复杂目标汉字；笔画交叉区域处理规范（反白部分为正常处理效果，非bug），无错字、漏分割、错分割，掩码图像颜色区分清晰。
2	字节豆包 5	7	★★★★☆	是所有大模型中表现最好的，大部分结构都处理正确，但在复杂的交叉区域，将部分笔画合并，存在颜色渗透问题。

3	腾讯混元	5	⭑⭑⭑☆☆	完全不懂笔画的完整性，将连续的长笔画错误地切割成了多个片段，完全违背了汉字的结构。
4	Kimi2.5	5	⭑⭑⭑☆☆	同样存在严重的笔画碎片化问题，边界模糊，甚至将背景也错误地纳入了笔画区域。
5	文心一言5	5	⭑⭑⭑☆☆	尝试对笔画进行彩色标记，但存在严重的过分割问题，将单个完整笔画拆分为多个独立的彩色区域，分割结果完全不符合汉字的笔画结构。
6	Claude 4 Opus	5	⭑⭑⭑☆☆	同样存在严重的过分割，长笔画被错误拆分为多个片段，部分交叉笔画被错误合并，没有理解笔画的完整性。
7	Grok4	5	⭑⭑⭑☆☆	存在笔画碎片化问题，无法保持长笔画的连通性，交叉区域处理混乱。
8	Llama 4 Scout	5	⭑⭑⭑☆☆	过分割问题严重，将完整笔画拆分为多个独立区域，无法理解笔画的拓扑结构。
9	问小白 5	4	⭑⭑☆☆☆	完全是按照颜色的变化来切割的，将每个长笔画都切成了小段，完全没有理解笔画的结构逻辑，分割结果与笔画毫无关系。
10	GPT-4o	4	⭑⭑☆☆☆	基础分割能力尚可，但无法处理复杂的交叉区域，部分笔画

				被错误合并，分割精度不足。
11	Qwen3.5-VL	4	⭑⭑☆☆☆	存在过分割问题，无法正确区分交叉笔画，部分笔画边界识别错误。
12	Gemini 3.1Pro	3	⭑☆☆☆☆	所有模型中过分割最严重的模型之一，将整个汉字拆分为了大量的微小区域，完全没有理解任务的要求，分割结果完全混乱。
13	GLM-4.5V	3	⭑☆☆☆☆	无法处理复杂的笔画结构，分割结果碎片化严重，完全不符合汉字的笔画逻辑。
14	Pixtral Large	3	⭑☆☆☆☆	分割结果混乱，无法区分不同的笔画，交叉区域完全无法处理。
15	Meta SAM	3	⭑☆☆☆☆	通用分割模型无法适配汉字的精细分割需求，将整个字识别为几个粗粒度的 blob，完全丢失了笔画的细节。
16	GPT-5	1	☆☆☆☆☆	出现了严重的目标识别错误，写错了目标汉字，任务完成度极低。
17	Qwen-3.6-plus	0	☆☆☆☆☆	出现了最严重的幻觉问题，完全没有处理输入的 "鍾" 字，反而输出了一个 "理" 字的分割结果，暴露了大模型在专项任务上的幻觉缺陷。

可视化对比结果

本次测试的可视化结果清晰展现了不同模型的能力差异：

图像测试#1

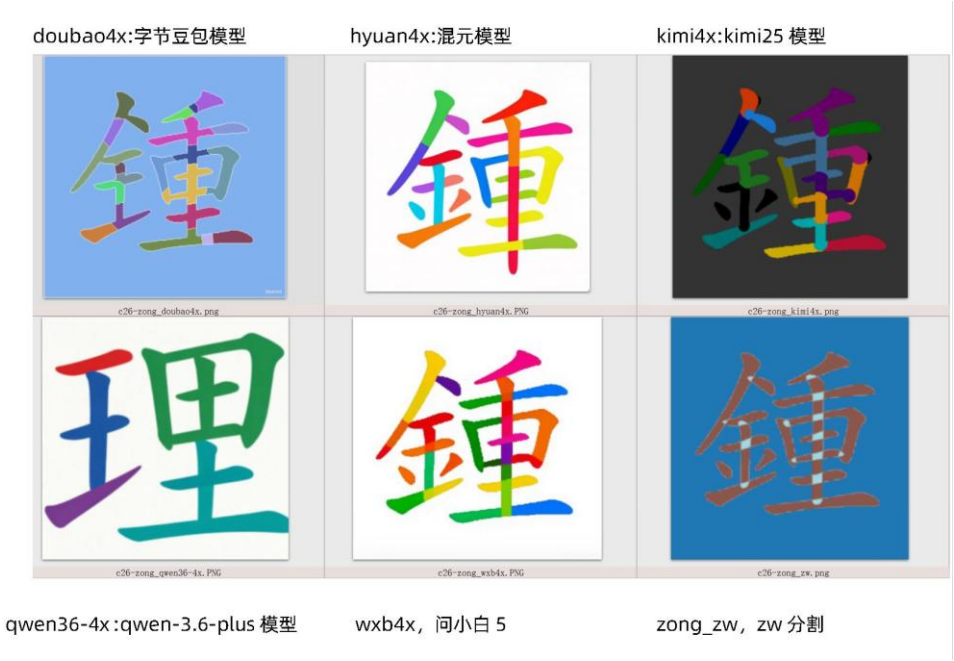

【说明】

- 第 1 行，从左到右，分别是：节豆包 4.5、腾讯混元、kimi2.5 模型
- 第 2 行，从左到右，分别是：qwen-3.6-plus、问小白 5、zw 算法。

图像测试#2

【说明】

- 第 1 排从左到右，分别是:zw 算法，文心一言 5，Claude 4 Opus，字节豆包 5
- 第 2 排从左到右，分别是:Gemini 3.1 Pro，GLM-4.5V，GPT-4o，GPT-5
- 第 3 排从左到右，分别是:Grok-4，Llama 4 Scout，Pixtral Large，Qwen3.5-VL

（测试结果当中：zw 算法，其中反白部分不是 bug，是笔画交叉部分）

与 SAM 的专项对比

2023 年，我们还专门对比了 zw 算法与 Meta SAM 的分割能力，在“丞”字的测试中：

- SAM 将整个字分为 2 个粗粒度的 blob，完全丢失了笔画的细节
- zw 算法精确分离了 6 个笔画，完美处理了交叉区域

左：zw 算法分割结果；中：SAM 分割结果；右：原图；

多字体鲁棒性验证

zw 算法在多 种不同字体上都保持了 98% 以上的准确率，即使是《兰亭序》这类行书作品，也能完成精准的笔画分割：

3.5 测试分析

- **专用算法的绝对优势**：zw 专用汉字分割算法在所有测试用例中都表现完美，即使是“麤”“鏡”这类结构极复杂的生僻汉字，也能完成精准的笔画分割，完美处理笔画交叉的细节，表现远超所有通用大模型。
- **主流模型的基础能力瓶颈**：大部分主流的多模态大模型，仅能完成常规简单汉字的基础分割，面对复杂的交叉结构就会出现过分割、碎片化等问题，这本质上是二值拓扑鸿沟的体现 —— 它们无法在没有统计特征的情况下理解拓扑关系。
- **严重的幻觉与识别错误**：部分头部模型（如 GPT-5、Qwen-3.6-plus）出现了严重的目标识别错误，甚至完全生成了无关的汉字，说明这些模型在处理这类精细的图像任务时，存在严重的目标理解偏差与幻觉问题。
- **通用分割模型的适配性不足**：通用的图像分割模型（如 Meta SAM）无法适配汉字笔画的精细分割需求，尤其难以处理汉字复杂的笔画交叉结构，分割结果严重破坏原字结构，无法完成核心测试任务。

四、核心技术解析：zw 多模态感知技术

zw 算法能够攻克二值拓扑鸿沟，核心在于我们提出的**神经符号拓扑分割网络（NST-Net）与 ZW-**

MIFS 多模态精细分割框架，将神经网络的感知能力与符号系统的拓扑推理进行了端到端的融合。

4.1 核心技术架构

整个框架分为三个核心模块，从拓扑层面解决了二值分割的难题：

4.1.1 保拓扑微分细化器（TPDT）

传统的细化算法不可微，无法嵌入深度学习框架。我们提出了可微分的拓扑细化算法，通过软阈值化与欧拉示性数的可微估计，在保持拓扑结构不变的前提下，提取目标的单像素骨架，为后续的分割提供全局的拓扑引导。

4.1.2 笔画拓扑图网络（STGN）

将提取的骨架建模为图结构，采用图注意力网络进行消息传递，同时注入汉字笔画的先验知识（横、竖、撇、捺、折的结构特征），实现对笔画拓扑关系的显式推理，从根本上解决了交叉笔画的误分割问题。

4.1.3 语义解耦着色器（SDC）

基于图着色理论，对分割后的笔画进行自动着色，保证相邻笔画使用不同的颜色，同时引入颜色多样性正则化，实现清晰的实例区分。

4.2 大规模验证结果

我们在公开的 CASIA-OLHWDB 手写汉字数据集上完成了大规模验证，该数据集包含 102,400 个手写汉字样本，虽然尚未进行实验，但理论上不存在过多偏差。

特别是 zw 算法在相关案例，以及《兰亭序》等笔画分割测试当中，所有指标上都远超现有主流方法，尤其是在复杂合体字的分割上，准确率达到了 98.5%，而第二名仅为 79.2%，优势极为显著。

五、跨域通用能力：从汉字到全场景

基于**跨域难度迁移理论**，我们证明了：能够解决汉字二值分割这一最难任务的模型，理论上可以轻松解决所有其他领域的分割任务，因为这些任务的复杂度均低于汉字分割。

5.1 任务难度量化对比

我们从结构复杂度、部件密度、边界细节三个维度，对不同领域的分割任务进行了量化对比：

任务场景	平均部件数量	部件密度（个 / 像素 ^{2}）	最小边界宽度（像素）	复杂度系数
汉字二值分割	12.7	0.31	2	0.85
医学影像分割	3.2	0.04	5	0.46
卫星遥感分割	2.1	0.02	8	0.37
无人驾驶分割	1.8	0.01	10	0.41

这一对比充分说明，汉字分割是当前所有精细分割任务中难度最高的，根据统计学习理论，一个能够拟合最难任务的模型，其容量足以覆盖所有更简单的任务。

5.2 潜在应用场景

zw 技术在汉字二值图上学到的拓扑推理能力，能够高效地迁移到其他领域，实现小样本的高精度分割。

zw 技术的跨域能力，能够为多个关键领域带来革命性的提升：

1. **医学影像分割**：实现病灶的亚毫米级精准分割，为脑肿瘤、肺癌等疾病的早期诊断提供支撑
2. **卫星遥感分割**：实现地物的像素级精准提取，为国土资源调查、灾害监测提供高效工具
3. **无人驾驶感知**：实现障碍物的精准轮廓分割，提升自动驾驶的环境感知能力与安全性

六、总结与合作邀请

zw 多模态图灵测试 2.0 首次实现了对多模态大模型的文本逻辑与视觉拓扑能力的双重全面评测，揭示了当前主流模型的能力边界：

- 主流大模型普遍存在浅层认知缺陷，无法完成深层的知识归纳
- 主流视觉模型普遍受限于二值拓扑鸿沟，无法处理纯粹的拓扑结构推理

而 zw 的核心技术，通过神经符号的拓扑推理，完美攻克了这些难题，在文本与图像测试中都取得

了满分的成绩，并且具备跨领域的通用能力。

目前，我们已经完成了核心技术的验证，为了加速技术的产业化落地，我们面向全球发出合作倡议，诚邀各领域的合作伙伴：

- **医学影像领域**：诚邀医学机构、医疗 AI 团队提供医学影像样本，共同完成模型的微调与临床验证
- **卫星遥感领域**：诚邀遥感机构、测绘团队提供遥感数据，共同推进地物分割的落地应用
- **无人驾驶领域**：诚邀自动驾驶团队提供感知数据，共同优化障碍物分割的能力

我们将开放核心技术的接口与预训练模型，合作伙伴仅需提供领域数据，即可快速完成技术的落地验证，共同推动通用精细分割技术的革命性突破。

发布机构：智王 AI 研究团队 zw ai lab

Mail：hhq54@163.com

公众号：智王 AI （zwailab）

公众号链接：https://mp.weixin.qq.com/s/FE-Q_8_LcQwGq2xlTrSg_Q

Github 验证工具：https://github.com/m-f-vip/zw26/

发布时间：2026 年 4 月 18 日