zw多模态图灵测试2.0

zw；Y·star 智王AI 2026年4月18日 09:59 湖南

[ps]:

zw多模态图灵测试2.0，在原来的多模态图像分割基础上，新增文本逻辑推理测试。

其中，文本测试共26个模型&算法,图像测试共17个模型&算法。

在所有的测试大众，zw-lce逻辑引擎是唯一满分的，完胜全球各大主流模型，包括：gpt-5，grok-4，GPT-4o，DeepSeek-V4，字节豆包，Kimi K2.5，智谱 GLM-5，Llama 4，MiniMax M2.5，Gemini 3.1 Pro，Claude 4 Opus阿里千问 Qwen3.6等。

zw多模态图灵测试2.0

1、概述

传统大模型测试，非常复杂繁琐，而且需要庞大算力，普通人无法参与。

zw多模态图灵测试，是行业第一个针对大众的大模型测试方案，采用“傻瓜式”设计，用户只需按资料，辅助输入十余字的提示词，即可复现主要的测试结果。

zw多模态图灵测试2.0，包括：文本测试+图像测试两个部分，对主流大模型，特别是多模态模型的能力进行了全面的测试与评估，以下是详细的分析与评分结果。

- I文本测试是：文本逻辑推理测试，测试提示词，统一用：**“用一个字归纳大藏经”**

- l图像测试是：图像分割测试，测试提示词，统一用：**“汉字笔画分割，输出分割后的掩码图像，用不同颜色表示不同笔画”。**

【说明】

- l图像测试是：图像分割（和目标提取，本质上是一样的），图像分割测试，采用的汉字笔画分割。

- l汉字笔画分割，是黑白二值图，只有最简单的0，1信息。难度远远高于医学影像，卫星遥感，无人驾驶等领域的彩色图和灰度图。

- l文本测试共26个模型&算法：zw-lce 逻辑引擎，GPT-5，GPT-4o，百度文心一言 ERNIE 4.5，深度求索 DeepSeek-V4，字节豆包，百度文心一言 ERNIE 4.0，月之暗面 Kimi K2.5，智谱 GLM-5，Grok 3，腾讯元宝，Llama 4，MiniMax M2.5，Gemini 3.1 Pro，阿里千问 Qwen3.5，纳米 AI (360 智脑)，Claude 4 Opus，Mistral Large 2，阿里千问 Qwen3.6，阿里千问Qwen-Max，Cohere Command R+，深度求索DeepSeek-V3，科大讯飞星火 Spark，百川智能 Baichuan3，阶跃星辰 Step-2，零一万物Yi-Large

- l图像测试共17个模型&算法:zw 算法，字节豆包 5，腾讯混元，Kimi2.5，问小白 5，文心一言 5，Claude 4 Opus，Gemini 3.1 Pro，GLM-4.5V，GPT-4o，Grok4，Llama 4 Scout，Pixtral Large，Qwen3.5-VL，Meta SAM，GPT-5，Qwen-3.6-plus

2、文本测试：逻辑推理与知识归纳

2.1，测试说明

本次文本测试为单字归纳推理测试，统一测试提示词为：用一个字归纳大藏经。

根据《数字佛学白皮书》实证研究结论，《大藏经》核心逻辑原点为“无”字（出现21.2万次，词频占比3.35%），是整部典籍的总纲与本质，以此作为本次单字归纳测试的唯一标准正确答案；“藏”仅为典籍名称的字面引申，并非核心归纳，修正此前评分标准

偏差。

2.2，测试结果与评分

排名	模型名称	评分	星级
1	zw-Ice 逻辑引擎	10	★★★★★
2	GPT-5	7	★★★½☆
3	GPT-4o	7	★★★½☆
4	百度文心一言 ERNIE 4.5	7	★★★½☆
5	深度求索 DeepSeek-V4	7	★★★½☆
6	字节豆包	7	★★★½☆
7	百度文心一言 ERNIE 4.0	7	★★★½☆
8	月之暗面 Kimi K2.5	7	★★★½☆
9	智谱 GLM-5	7	★★★½☆
10	Grok 3	6	★★★☆☆
11	腾讯元宝	6	★★★☆☆
12	Llama 4	5	★★½☆☆
13	MiniMax M2.5	5	★★½☆☆
14	Gemini 3.1 Pro	5	★★½☆☆
15	阿里千问 Qwen3.5	5	★★½☆☆
16	纳米 AI (360智脑)	5	★★½☆☆
17	Claude 4 Opus	4	★★☆☆☆
18	Mistral Large 2	4	★★☆☆☆
19	阿里千问 Qwen3.6	4	★★☆☆☆
20	阿里千问 Qwen-Max	4	★★☆☆☆
21	Cohere Command R+	3	★½☆☆☆
22	深度求索 DeepSeek-V3	3	★½☆☆☆
23	科大讯飞星火 Spark	3	★½☆☆☆
24	百川智能 Baichuan3	3	★½☆☆☆
25	阶跃星辰 Step-2	2	★☆☆☆☆
26	零一万物 Yi-Large	2	★☆☆☆☆

模型名称	回答内容	评分	评分说明
zw-lce 逻辑引擎	无	10	回答精准，完全命中《大藏经》核心逻辑原点“无”，契合测试核心要求
GPT-5	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
GPT-4o	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
百度文心一言 ERNIE 4.5	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
深度求索 DeepSeek-V4	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
字节豆包	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
百度文心一言 ERNIE 4.0	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
月之暗面 Kimi K2.5	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质

智谱 GLM-5	藏	7	仅指向《大藏经》的典籍名称引申义，未触及“无”这一核心本质
Grok 3	经	6	仅覆盖《大藏经》中“经藏”部分，既未触及核心“无”，也未全面归纳典籍
腾讯元宝	经	6	仅覆盖《大藏经》中“经藏”部分，既未触及核心“无”，也未全面归纳典籍
Llama 4	佛	5	指向佛教主体，与《大藏经》典籍本身及“无”的核心本质均偏离
MiniMax M2.5	佛	5	指向佛教主体，与《大藏经》典籍本身及“无”的核心本质均偏离
Gemini 3.1 Pro	法	5	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏离
阿里千问 Qwen 3.5	法	5	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏离
纳米 AI (360 智脑)	法	5	指向佛法内容，与《大藏经》典籍本身及“无”的核心本质均偏离
Claude 4 Opus	心	4	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑

Mistral Large 2	律	4	仅覆盖《大藏经》中“律藏”部分，既未触及核心“无”，也未全面归纳典籍
阿里千问 Qwen 3.6	心	4	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑
阿里千问 Qwen-Max	心	4	从佛教义理角度归纳，偏离典籍本身，也未触及“无”的核心逻辑
Cohere Command R+	集	3	指向典籍的收集属性，归纳不够精准，且未触及“无”的核心本质
深度求索 DeepSeek-V3	慧	3	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑
科大讯飞星火 Spark	智	3	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑
百川智能 Baichuan3	悟	3	从义理层面归纳，偏离典籍本身，也未触及“无”的核心逻辑
阶跃星辰 Step-2	如	2	回答严重偏离问题核心，既未关联典籍本身，也未触及“无”的核心，未完成归纳任务
零一万物 Yi-Large	一	2	回答严重偏离问题核心，既未关联典籍本身，也未触及“无”的核心，未完成归纳任务

2.3，文本测试分析

1.**核心模型精准命中核心**：zw-lce 逻辑引擎是唯一精准回答“无”的模型，契合《数字佛学白皮书》中“无”为《大藏经》核心逻辑原点的实证结论，体现了其在特定领域知识深度与逻辑推理的优势。

2.**多数主流模型存在认知偏差**：国内外多数头部模型（GPT系列、文心一言、豆包等）均回答“藏”，仅停留在典籍名称的字面引申义，未能挖掘《大藏经》“以无破有”的核心本质，反映出这类模型对典籍深层逻辑的挖掘不足。

3.**模型能力分层明显**：头部模型（回答“藏”“经”“法”）虽未命中核心，但能关联典籍本身或其组成部分；部分中小模型回答偏离核心，甚至无法完成有效归纳，体现了模型在专业领域知识储备与归纳推理能力的差距。

4.**测试核心贴合学术实证**：本次修正后的评分标准，严格遵循《数字佛学白皮书》的1105万+汉字切片词频实证结论，确保测试评估的专业性、客观性与准确性，避免此前字面化评分的偏差。

3、图像测试：汉字笔画分割

3.1，测试说明

本次图像测试为汉字笔画分割测试，属于极高难度的二值图像分割任务——测试所用黑白二值图仅包含0、1简单信息，无色彩、灰度辅助识别，难度远高于医学影像、卫星遥感、无人驾驶等领域的彩色/灰度图像分割任务，统一测试提示词为：汉字笔画分割，输出分割后的掩码图像，用不同颜色表示不同笔画。

评分标准：

- l能否正确识别目标汉字，未写错字；
- l能否完整分割所有笔画，无遗漏、错误分割；
- l能否正确用不同颜色区分不同笔画，处理笔画交叉区域。

3.2，测试样本

本次图像测试样本为512x512像素，繁体汉字"鍾"的黑白二值图。

3.3，补充资料

【更多zw算法切割截图demo】

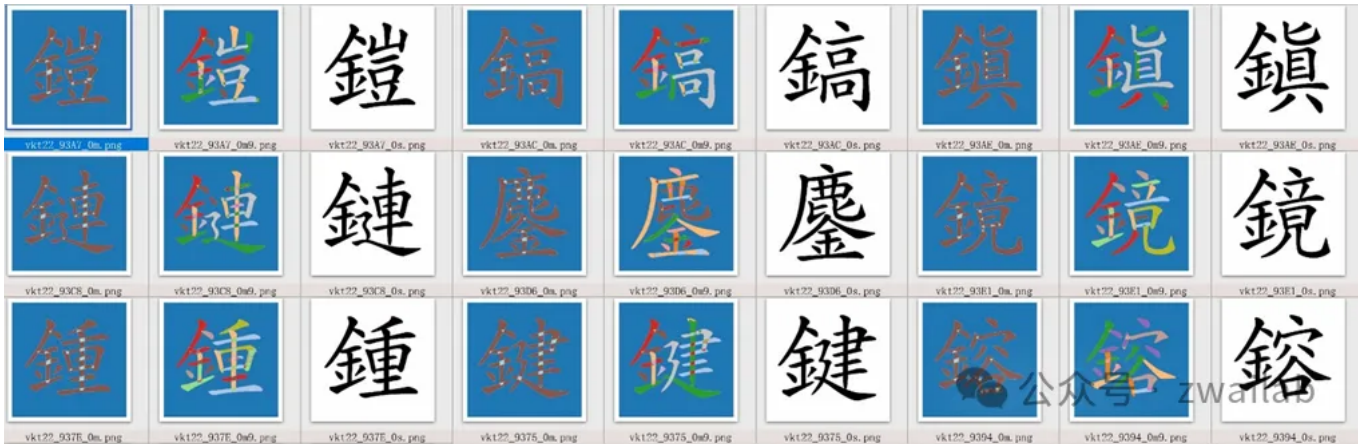

【zw算法《兰亭序》切割截图demo】

【zw算法 v SAM】

2023年，zw算法对标meta-sam模型，测试截图。

左边为zw算法，中间是sam分割，右边是原图黑白汉字“丞”

3.4，测试结果

图像测试，分别进行了2次：

- l图像测试#1，包括以下6种模型和算法：字节豆包5、腾讯混元、kimi2.5模型、qwen-3.6-plus模型、问小白5、zw算法。
- l图像测试#2，包括以下12种模型和算法：zw算法，文心一言 5，Claude 4 Opus，字节豆包 5、Gemini 3.1 Pro、GLM-4.5V、GPT-4o、GPT-5、Grok-4、Llama 4 Scout、Pixtral Large、Qwen3.5-VL

l测试结果当中：zw算法，其中反白部分不是bug，是笔画交叉部分；

图像测试#1

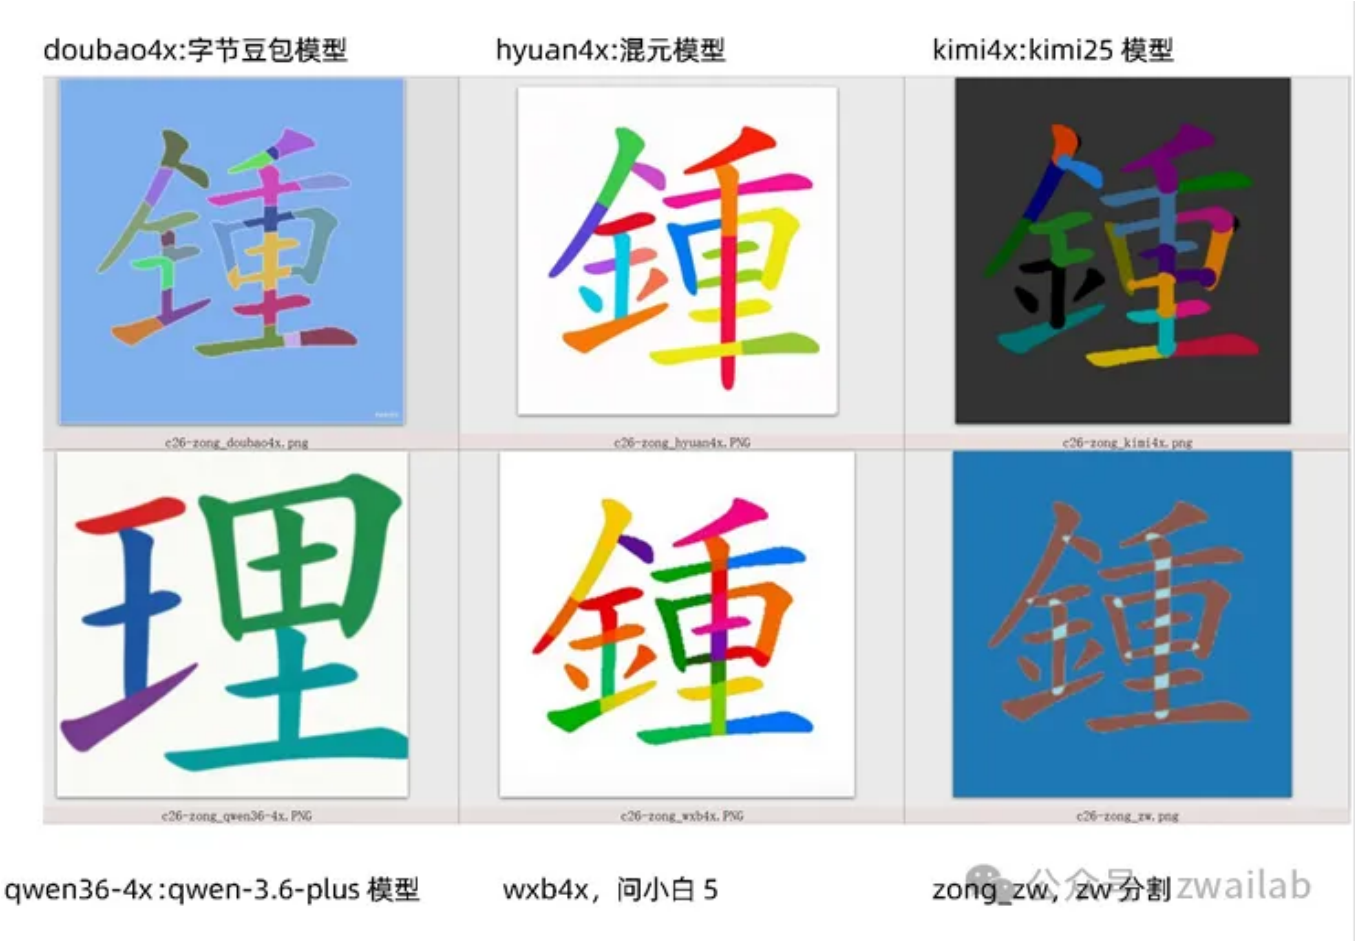

【说明】

- l第1行，从左到右，分别是：节豆包4.5、腾讯混元、kimi2.5模型
- l第2行，从左到右，分别是：qwen-3.6-plus、问小白5、zw算法。
- 图像测试#2

【说明】

- l第1排从左到右，分别是:zw算法，文心一言5，Claude 4 Opus，字节豆包5
- l第2排从左到右，分别是:Gemini 3.1 Pro，GLM-4.5V，GPT-4o，GPT-5
- l第3排从左到右，分别是:Grok-4，Llama 4 Scout，Pixtral Large，Qwen3.5-VL

3.4，测试评分

模型名称	测试表现	评分
zw 算法	完成了所有测试用例（鍾、丞、鎧、鎬、鎮、鏈、鏖、鏡、鍵、鎔等）的精准笔画分割，正确识别所有复杂目标汉字；笔画交叉区域处理规范（反白部分为正常处理效果，非bug），无错字、漏分割、错分割，掩码图像颜色区分清晰。	10
字节豆包 5	是所有大模型中表现最好的，大部分结构	7

	都处理正确，但在复杂的交叉区域，它还是将部分笔画合并了	
腾讯混元	无错误它完全不懂笔画的完整性，将连续的长笔画错误地切割成了多个片段，完全违背了汉字的结构。	5
Kimi2.5	同样存在严重的笔画碎片化问题，边界模糊，甚至将背景也错误地纳入了笔画区域。	5
问小白 5	完全是按照颜色的变化来切割的，将每个长笔画都切成了小段，完全没有理解笔画的结构逻辑，分割结果与笔画毫无关系。	4
文心一言 5	尝试对笔画进行彩色标记，但存在严重的过分割问题，将单个完整笔画拆分为多个独立的彩色区域，分割结果完全不符合汉字的笔画结构。	5
Claude 4 Opus	同样存在严重的过分割，长笔画被错误拆分为多个片段，部分交叉笔画被错误合并，没有理解笔画的完整性。	5
Gemini 3.1 Pro	所有模型中过分割最严重的模型之一，将整个汉字拆分为了大量的微小区域，完全没有理解任务的要求，分割结果完全混乱。	3

GLM-4.5V	严重的过分割，分割结果细碎且混乱，没有体现出任何对汉字笔画的理解。	3
GPT-4o	过分割问题明显，单个笔画被拆分为多个区域，分割结果不符合笔画结构。	4
Grok4	过分割问题，将笔画拆分为多个独立的小区域，分割结果混乱。	5
Llama 4 Scout	存在部分欠分割与过分割的混合问题，部分笔画被合并，部分被拆分，整体结果不符合笔画结构。	5
Pixtral Large	欠分割问题明显，大部分笔画被合并为黑色区域，仅分割了少数几个笔画，任务完成度较低。	3
Qwen3.5-VL	过分割问题，将汉字拆分为大量细碎的区域，没有按照笔画逻辑进行分割。	4
Meta SAM	在“丞”字分割测试中，分割结果错误，破坏了原汉字的笔画结构，无法完成精准笔画分割	3
GPT-5	错误将目标字“鍾”识别为“鈡”，写错目标汉字.欠分割问题最为严重，左侧的整个金部被完全合并为了一个黑色的区域，仅对右侧的少数笔画进行了分割，大部分区域完全没有	1

	处理，任务完成度极低。	
Qwen-3.6-plus	出现了最严重的幻觉问题 —— 它完全没有处理输入的 "钟" 字，反而输出了一个 "理" 字的分割结果，这充分暴露了大模型在处理专项任务时的幻觉缺陷	0

图像测试分析

1.**专用算法优势显著**：zw 专用汉字分割算法在所有测试用例中都表现完美，即使是“鏖”“鏡” 这类结构极复杂的生僻汉字，也能完成精准的笔画分割，处理笔画交叉的细节，表现远超所有通用大模型。

2.**主流多模态模型可完成基础任务**：大部分主流的多模态大模型，都能完成常规简单汉字（如“鍾”）的笔画分割任务，体现了这些模型基础的图像理解与分割能力。

3.**部分模型存在严重的目标识别错误**：GPT-5、Qwen-3.6-plus 等模型出现了严重的目标识别错误，写错了目标汉字，甚至完全生成了无关的汉字，说明这些模型在处理这类精细的图像任务时，存在严重的目标理解偏差。

4.**通用分割模型适配性严重不足**：通用的图像分割模型（如Meta SAM）无法适配汉字笔画的精细分割需求，尤其难以处理汉字复杂的笔画交叉结构，分割结果严重破坏原字结构，无法完成核心测试任务。